第一周学习周报

He Song | 2026 年 10 月 3 日

摘要：本周期完成了 freeCodeCamp 响应式网页设计课程及 JavaScript 部分，以及 Kaggle Python、Pandas 两门微课程；使用 Git 管理学习项目并推送至 GitHub；并选取了相关数据集以便后续使用。同时订阅了相关学者的学术动态。通过这些学习，我初步了解了网页开发、数据处理与版本管理在后续实践中的作用。目前主要的疑惑是，大模型 Agent 与可视化、HCI 在具体研究中如何结合。

1 任务要求

《课题组新成员入门学习计划》将第 1–2 周设为基础技能阶段，主要要求如下。

表 1 基础技能阶段的学习要求

学习部分	应完成的内容
Web 开发	完成 Responsive Web Design；JavaScript 学至基础算法部分，重点掌握 DOM 操作与 Promise、`fetch` 等异步编程。
Python 数据处理	学习 Python 基础，完成 Kaggle Python 和 Pandas 微课程；第 2 周末选定公开数据集，完成清洗、基本统计及一页数据概况。
Git 与 GitHub	掌握 git、commit、branch、merge 和 push，完成 Introduction to GitHub 入门练习。

2 Web 开发学习

已完成 freeCodeCamp 响应式网页设计课程并取得认证，JavaScript 的 "DOM 操作" 和 "异步编程" 部分也已完成。

通过学习，我更清楚了 HTML、CSS 与 JavaScript 的分工。尤其是描述性 HTML 和表现性 HTML 的区别是我之前没有涉足的。这些内容为后续制作交互式展示页面打下了基础。



图 1 freeCodeCamp 响应式网页设计证书

3 Python 与 pandas 学习

已完成 Kaggle Python 和 Pandas 两门微课程。我的主要收获是了解了如何用 Python 组织数据处理过程，并用 pandas 进行筛选与统计。



图 2 Kaggle Python 完成证书



图 3 Kaggle Pandas 完成证书

4 版本控制与学术关注

已使用 Git 管理学习项目，并通过 `git push` 提交到了 GitHub 的 *Private Repo* 中。

已订阅 Huamin Qu、Ashish Vaswani 和 Duen Horng Chau 的学术动态，希望逐步了解相关研究。

5 数据集的选取

我选取了数据集 Data Science, AI & ML Job Salaries in 2025 作为我后续任务的数据集。

通过 python 代码，对数据进行了初步的清洗和整理：

python 代码：

```
import pandas as pd

url = "/Users/mason/Desktop/Ma's Lab/Getting Start/Dataset/salaries.csv"
raw = pd.read_csv(url)
```

```
print("数据规模: ", raw.shape)
print(raw.head())
raw.info()

data = raw.copy()
data.columns = data.columns.str.strip()

for col in data.select_dtypes(include=["object", "string"]).columns:
    data[col] = data[col].str.strip().replace("", pd.NA)

data["salary_in_usd"] = pd.to_numeric(
    data["salary_in_usd"], errors="coerce"
)

print("\n各列缺失值: ")
print(data.isna().sum())

print("\n完全相同的额外行数: ", data.duplicated().sum())

invalid_salary = (
    data["salary_in_usd"].isna()
    | data["salary_in_usd"].le(0)
)
print("无法用于薪资分析的行数: ", invalid_salary.sum())

clean = data.loc[~invalid_salary].copy()

print("\n美元薪资描述统计: ")
print(clean["salary_in_usd"].describe().round(2))

print("\n记录数最多的 5 个岗位: ")
print(clean["job_title"].value_counts().head(5))

print("\n按经验等级统计薪资: ")
print(
    clean.groupby("experience_level")["salary_in_usd"]
    .agg(["count", "mean", "median"])
    .reindex(["EN", "MI", "SE", "EX"])
    .round(2)
)

print("\n公司所在地区占比（前 5）: ")
print(
    clean["company_location"]
    .value_counts(normalize=True)
    .head(5)
    .mul(100)
    .round(2)
)
```

输出结果:

```
数据规模: (151445, 11)
   work_year experience_level employment_type       job_title  ...
0       2025               EX              FT    Head of Data  ...
1       2025               EX              FT    Head of Data  ...
2       2025               SE              FT  Data Scientist  ...
3       2025               SE              FT  Data Scientist  ...
4       2025               MI              FT        Engineer  ...

  employee_residence remote_ratio  company_location company_size
0                 US            0                US            M
1                 US            0                US            M
2                 US            0                US            M
3                 US            0                US            M
4                 US          100                US            M

[5 rows x 11 columns]
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 151445 entries, 0 to 151444
Data columns (total 11 columns):
 #   Column              Non-Null Count   Dtype
---  ------              --------------   -----
 0   work_year           151445 non-null  int64
 1   experience_level    151445 non-null  object
 2   employment_type     151445 non-null  object
 3   job_title           151445 non-null  object
 4   salary              151445 non-null  int64
 5   salary_currency     151445 non-null  object
 6   salary_in_usd       151445 non-null  int64
 7   employee_residence  151445 non-null  object
 8   remote_ratio        151445 non-null  int64
 9   company_location    151445 non-null  object
 10  company_size        151445 non-null  object
dtypes: int64(4), object(7)
memory usage: 12.7+ MB

各列缺失值:
work_year             0
experience_level      0
employment_type       0
job_title             0
salary                0
salary_currency       0
salary_in_usd         0
employee_residence    0
remote_ratio          0
company_location      0
company_size          0
dtype: int64

完全相同的额外行数: 79532
```

```
无法用于薪资分析的行数： 0

美元薪资描述统计：
count    151445.00
mean     157527.46
std       74150.77
min       15000.00
25%      105800.00
50%      146100.00
75%      198000.00
max      800000.00
Name: salary_in_usd, dtype: float64

记录数最多的 5 个岗位：
job_title
Data Scientist       18751
Software Engineer    16948
Data Engineer        16352
Data Analyst         13779
Engineer             11004
Name: count, dtype: int64

按经验等级统计薪资：
                   count       mean    median
experience_level
EN                 13663   98961.74   86600.0
MI                 46128  142301.18  130000.0
SE                 87491  172657.76  161000.0
EX                  4163  200471.43  189370.0

公司所在地区占比（前 5）：
company_location
US    89.52
CA     4.10
GB     2.76
AU     0.39
NL     0.32
Name: proportion, dtype: float64
```

6 疑惑与希望获得的指导

Agent 主要研究如何让大模型自主完成复杂任务，看起来与可视化、HCI 有些差异，为什么课题组会同时选择这三个方向？“为 Agent 设计人机协作界面”是否是它们的主要连接点，还是还有其他交叉方式？